

Predicción de radiación solar mediante variables meteorológicas

EQUIPO N 10

Mónica Sánchez · Gloria Alain · Angel Herrera · Ricardo Vargas

Universidad Tecnológica de Panamá — Maestría en Analítica de Datos

S100 — Introducción a la Ciencia de Datos · Parte II: Reporte Final · 23 de septiembre de 2026

Resumen ejecutivo

Este estudio evalúa la predicción de radiación solar a una hora utilizando datos meteorológicos horarios de Panamá entre 2022 y 2026. Se comparó un baseline de persistencia con Ridge Regression y XGBoost, utilizando una división cronológica de entrenamiento y prueba y validación temporal para el ajuste de XGBoost. El modelo XGBoost obtuvo el mejor desempeño, con un RMSE de 49.30 W/m² en todas las horas y 67.69 W/m² al considerar únicamente horas con radiación solar. Además, la incorporación de variables meteorológicas redujo el RMSE en 19.5 % frente al modelo basado en información histórica de radiación, respaldando la hipótesis de que las condiciones meteorológicas aportan información relevante para el pronóstico a corto plazo.

1. Introducción

En Panamá, la creciente incorporación de la energía solar hace necesario contar con estimaciones confiables de radiación solar, cuya variabilidad está estrechamente relacionada con las condiciones atmosféricas y puede afectar la disponibilidad del recurso energético. En este contexto, se plantea determinar en qué medida variables meteorológicas como la temperatura, la humedad relativa y la nubosidad, junto con los registros históricos de radiación, permiten predecir la radiación solar a corto plazo. Se parte de la hipótesis de que la incorporación conjunta de variables meteorológicas y registros históricos de radiación permitirá obtener predicciones con menor error que aquellas basadas únicamente en los valores históricos de radiación.

2. Datos y preparación

Los datos meteorológicos se obtuvieron mediante la API histórica de Open-Meteo, para una planta solar en Panamá. Para los años recientes, Open-Meteo dispone de datos históricos derivados del European Centre for Medium-Range Weather Forecasts (ECMWF). El período analizado comprende desde 2022 hasta 2026, con frecuencia horaria. El conjunto contiene 35,088 filas y 16 columnas, y cada fila representa las condiciones meteorológicas correspondientes a la hora específica. La variable objetivo es la radiación solar global una hora hacia adelante (W/m²). Entre las principales variables se consideran la radiación de la hora actual (W/m²), la radiación directa (W/m²), la temperatura a 2 m (°C), la humedad relativa (%) y los valores históricos de radiación (W/m²). También se incluyen la presión superficial (hPa), la cobertura nubosa (%), la precipitación (mm) y la radiación difusa (W/m²) para evaluar su aporte durante el modelado.

Durante la preparación, los datos fueron ordenados cronológicamente y se verificó la presencia de valores faltantes, valores atípicos y rangos físicamente no posibles. Al no mantener valores nulos, no fue necesaria la imputación. Se analizaron las distribuciones mediante histogramas, observándose una distribución asimétrica de la radiación, con una alta concentración de valores cercanos a cero.

Además, se generaron variables cronológicas como la hora del día y el día del año, con el propósito de representar los patrones temporales asociados al ciclo diario y estacional de la radiación. También se generaron rezagos de radiación y potencia de una, dos y tres horas para incorporar información histórica. Se eliminaron las variables de radiación directa y difusa debido a su redundancia con la radiación global. Finalmente, se conservaron 35,084 observaciones y 11 variables predictoras. Para el modelo Ridge se aplicó estandarización mediante StandardScaler utilizando únicamente los datos de entrenamiento, mientras que XGBoost no requirió escalamiento.

3. Métodos

Para evaluar la capacidad de los modelos para predecir la radiación solar una hora hacia adelante, los datos se dividieron cronológicamente en un 80 % para entrenamiento y 20 % para prueba. Se mantuvo el orden temporal para

evitar que observaciones futuras fueran utilizadas durante el entrenamiento. Además, se dejó una separación de una observación entre ambos conjuntos debido al desplazamiento de una hora aplicado a la variable objetivo. El `random_state` utilizado en XGBoost fue 42; la partición de los datos no utilizó una semilla aleatoria, ya que se realizó de forma cronológica.

Como modelo de referencia se utilizó el baseline de persistencia, que considera como predicción para la siguiente hora el valor actual de radiación. Adicionalmente, se compararon dos algoritmos supervisados: Ridge Regression y XGBoost Regression.

Para la validación del modelo XGBoost se utilizó `TimeSeriesSplit` con 5 folds y `gap=1`, manteniendo el orden temporal de las observaciones. El `gap=1` evita utilizar directamente la observación inmediatamente adyacente entre entrenamiento y validación. La selección de los hiperparámetros de XGBoost se realizó mediante `GridSearchCV`, evaluando 108 combinaciones de hiperparámetros y utilizando el RMSE negativo (`neg_root_mean_squared_error`) como función de evaluación. Se seleccionó la combinación que obtuvo el menor RMSE promedio en los cinco folds de validación.

El desempeño se evaluó mediante MAE, RMSE y R^2 , tanto para el conjunto de entrenamiento como para el conjunto de prueba. El RMSE es la métrica principal, ya que penaliza en mayor medida los errores grandes, aspecto relevante para la predicción de radiación solar, donde errores elevados pueden representar diferencias importantes respecto al valor real

4. Resultados

Las Tablas 1 y 2 confirman el mismo orden entre modelos: persistencia, Ridge y XGBoost, de peor a mejor desempeño. En la Tabla 1, XGBoost obtiene un RMSE de prueba de 49.30 frente a 81.79 de Ridge y 118.09 de la persistencia, con una brecha pequeña entre entrenamiento y prueba (45.41 y 49.30) que indica poco sobreajuste. En la Tabla 2, restringida a horas con sol, el error de los tres modelos sube considerablemente (persistencia a 162.00, Ridge a 106.32, XGBoost a 67.69), porque en la Tabla 1 casi la mitad de las observaciones nocturnas con radiación cero hacía parecer mejor el desempeño general; aun así, XGBoost mantiene su ventaja también en este escenario más exigente.

Tabla 1. Comparación de modelos (RMSE, W/m²).

Modelo	RMSE (entrenamiento)	RMSE (validación cruzada)	RMSE (prueba)
Baseline (persistencia)			118.09 W/m ²
Ridge	86.34 W/m ²		81.79 W/m ²
XGBoost	45.50 W/m ²	51.83 W/m ²	49.30 W/m ²

Tabla 2. Comparación de modelos solo horas con sol (RMSE, W/m²).

Modelo	RMSE (prueba)
Baseline (persistencia)	162.00 W/m ²
Ridge	106.32 W/m ²
XGBoost	67.69 W/m ²

Adicionalmente, se presenta en la Tabla 3 la evaluación de dos configuraciones del modelo, con el objetivo de analizar el aporte de las variables meteorológicas. La primera configuración utiliza únicamente variables históricas de radiación, mientras que la segunda incorpora, además, variables meteorológicas. Los resultados muestran que el modelo basado únicamente en los rezagos de radiación presenta un mayor error de predicción, con un RMSE de 61.25 W/m², frente a 49.30 W/m² obtenido al incorporar las variables meteorológicas.

Tabla 3. Comparación de modelos con y sin variables meteorológicas (RMSE, W/m²).

Modelo	RMSE (prueba)
Solo Rezagos de Radiación	61.25 W/m ²
Con Variables Metereológicas	49.30 W/m ²

La Figura 1 muestra qué tanto pesa cada variable en las decisiones del modelo XGBoost. La radiación actual (*rad_om*) concentra el 74 % de la importancia, seguida por la hora del día con un 15 %, de manera que entre ambas explican cerca del 89 % del modelo, lo cual es coherente con la física del problema, ya que la hora captura el ciclo de salida y puesta del sol. Las variables meteorológicas exógenas, es decir, precipitación, temperatura, nubosidad y humedad, aportan individualmente entre 1 % y 3 % cada una, y los rezagos de radiación (*rad_lag_1h*, *rad_lag_2h*, *rad_lag_3h*) resultan casi irrelevantes por separado. Aun así, el efecto conjunto de las variables meteorológicas reduce el RMSE en un 19.5 % frente a un modelo sin ellas.




Figura 1. Importancia de variables del modelo XGBoost.

La Figura 2 compara, hora por hora, la radiación real con las predicciones de persistencia y XGBoost durante una semana del conjunto de prueba. Ambos modelos siguen el ciclo diario básico, pero difieren en los picos y en las caídas abruptas causadas por nubosidad: la persistencia se rezaga un paso, mientras que XGBoost sigue la curva real con mayor precisión. Aun así, el modelo comete errores puntuales, como el 28 de agosto, donde sobreestima el pico real en más de 100 W/m². Esto ilustra, de forma visual, la ventaja de XGBoost que ya mostraba la Tabla 1 (RMSE de 118.09 frente a 49.30 W/m²).




Figura 2. Radiación real vs. persistencia vs. XGBoost.

5. Discusión, limitaciones y conclusión

El modelo XGBoost obtuvo un buen desempeño en la predicción de la radiación solar a una hora de anticipación, alcanzando un R^2 de 0.973 considerando todas las horas y de 0.948 al restringir la evaluación a las horas con radiación solar. Estos resultados muestran que el modelo logra representar una parte importante de la variabilidad de la radiación y presenta un desempeño superior al modelo de persistencia y al modelo lineal Ridge evaluados en este estudio.

En cuanto a la importancia de las variables, las variables con mayor contribución en el modelo XGBoost fueron la radiación global y la hora del día, seguidas por las variables meteorológicas. La relevancia de la radiación global y de la hora del día es consistente con la naturaleza temporal de la radiación solar. Además, la comparación entre modelos permite evaluar directamente la hipótesis planteada: el modelo que utiliza únicamente información histórica de radiación obtuvo un RMSE de 61.25 W/m^2 , mientras que el modelo que incorpora las variables meteorológicas obtuvo un RMSE de 49.30 W/m^2 . Esto representa una reducción del error de aproximadamente 19.5 % al incorporar información meteorológica.

Por lo tanto, los resultados respaldan la hipótesis de que las variables meteorológicas aportan información adicional al historial reciente de radiación para la predicción a una hora. Una decisión concreta derivada de este resultado sería mantener las variables meteorológicas como parte del conjunto de entrada del modelo, en lugar de utilizar únicamente los rezagos de radiación.

Entre las limitaciones del modelo está que se entrenó y evaluó con datos de una sola ubicación por lo cual no hay evidencia de que su desempeño se mantenga en zonas con datos meteorológicos distintos sin volver a entrenarlo, tampoco se puede concluir que funcione con horizontes de pronóstico distintos a una hora en el futuro.

Como trabajo futuro, se puede evaluar extender el modelo a horizontes de pronóstico más largos y evaluar el desempeño de un modelo filtrando las horas de sol del entrenamiento para que este se enfoque en predecir la radiación durante las horas de luz.

Referencias

- Redan, R., Ahmadipour, M., Othman, M., & Hasan, K. (2023). Random Forest (RF) with Daubechies Wavelet and Multiple Time Lags (MTL) for Solar Irradiance Forecasting. 2023 IEEE 3rd International Conference in Power Engineering Applications (ICPEA). Putrajaya: IEEE.
doi:<https://doi.org/10.1109/ICPEA56918.2023.10093181>

Vijay Babu, A., Bharath Kumar, N., Periyannan, S., Hosseinpour, A., & Flah, A. (2025). Solar Energy Forecasting Using Machine Learning Techniques for Enhanced Grid Stability. *IEEE Access*.

Zhong, Y.-J., & Wu, Y.-k. (2020). Short-Term Solar Power Forecasts Considering Various Weather Variables. *2020 International Symposium on Computer, Consumer and Control (IS3C)*. Taichung City, Taiwan: IEEE. doi:<https://doi.org/10.1109/IS3C50286.2020.00117>

Zippenfenig, P. (2023). *Open-Meteo.com Weather API [Computer software]*. Retrieved from Zenodo: <https://open-meteo.com/en/docs/historical-weather-api>

Declaración de uso de inteligencia artificial

Se utilizaron herramientas de inteligencia artificial como Claude y ChatGPT como apoyo para la depuración y revisión del código en Python, identificación y comprensión de errores y aclaración de conceptos relacionados con los modelos de aprendizaje. En particular, inicialmente se consideró el uso de un DummyRegressor; sin embargo, debido a que este baseline presentaba valores de error elevados, a partir de la interacción con las herramientas de inteligencia artificial se planteó utilizar la persistencia de la radiación como baseline, tomando el valor de radiación de la hora anterior como referencia para la predicción de la siguiente hora.